

Criação do Banco de Dados SQLite

AUTHOR

Miguel Fiorin

Carregando pacotes necessários

```
library(DBI)
library(RSQLite)
library(readr)
library(glue)
library(knitr)
library(kableExtra)
library(tibble)
```

Configurações Iniciais e Função de Importação de Arquivos TSV

Neste chunk, é criado um arquivo SQLite no diretório, sendo necessário que não exista previamente um arquivo com o nome "IMDB.db". Em seguida, estabelecemos o tamanho do chunk, isto é, a quantidade de linhas adicionadas ao banco de dados por iteração.

Por fim, definimos uma função para ler o arquivo .tsv de forma incremental, adicionando 200.000 linhas por iteração à tabela especificada no banco de dados.

Esse método é importante para evitar sobrecarga de memória. Além disso, permite substituir os valores "" por NA.

```
conn <- dbConnect(SQLite(), "IMDB.db")
chunk_sz = 200000

import_tsv <- function(tsv, name_table){
  dbExecute(conn, glue("DROP TABLE IF EXISTS {name_table}"))

  read_tsv_chunked(
    tsv,
    callback = DataFrameCallback$new(function(x, pos) {
      dbWriteTable(conn, name_table, x, append = TRUE)
    }),
    chunk_size = chunk_sz,
    na = "\\N"
  )
}
```

Importação dos Arquivos TSV para o Banco de Dados SQLite

```
import_tsv("title.ratings.tsv", "ratings")
import_tsv("title.basics0.tsv", "basics")
import_tsv("title.principals0.tsv", "principals")
```

Verificando se as tabelas foram importadas corretamente

Ao utilizar o PowerShell para verificar o número de linhas de cada arquivo TSV, por meio do comando `Get-Content arquivo.tsv | Measure-Object -Line`, obtivemos os valores apresentados na tabela a seguir.

```
contagem_df <- tibble(  
  Tabela = c("ratings", "basics", "principals"),  
  Linhas = c(1484616, 11144943, 88359623)  
)  
  
contagem_df %>%  
  kable(  
    col.names = c("Tabela", "Número de Linhas"),  
    align = "c",  
  ) %>%  
  kable_styling(full_width = FALSE, position = "center")
```

Tabela	Número de Linhas
ratings	1484616
basics	11144943
principals	88359623

É importante destacar que, na contagem via terminal, a primeira linha (cabeçalho) é incluída, enquanto no SQLite essa linha não é considerada nos registros da tabela.

```
dbGetQuery(conn , "SELECT COUNT(*) FROM ratings;")
```

```
COUNT(*)  
1 1484615
```

```
dbGetQuery(conn, "SELECT COUNT(*) FROM basics")
```

```
COUNT(*)  
1 11144942
```

```
dbGetQuery(conn, "SELECT COUNT(*) FROM principals")
```

```
COUNT(*)  
1 88359622
```

Portanto, assumimos que os arquivos foram bem importados para a base de dados .db

```
dbDisconnect(conn)
```